Лабораторная работа №3. Вариант B

Транспонирование матрицы и исследование локальности памяти

Система: Intel Core i5-1155G7, 4 ядра / 8 логических процессоров. Кеш на ядро: L1d 48 КиБ, L1i 32 КиБ, L2 1.25 МиБ; общий L3 8 МиБ. Компилятор GCC 16.2.0, OpenMP.

Тип double (8 Б), N_v = 3500. Время: omp_get_wtime(), один прогрев и медиана пяти запусков; выделение, заполнение и проверка памяти вне замера. Каждый запуск сравнивался с transpose_rows: 0 несовпадений. BW = $2 \cdot N^2 \cdot 8 / t / 10^9$ ГБ/с; S = T(rows, 1 поток) / T_p.

1. Порядок обхода, один поток

N	rows, с	cols, с	BW rows, ГБ/с	BW cols, ГБ/с
256	< 0.001	< 0.001	-	-
512	0.001	0.001	4.20	4.20
1024	0.015	0.004	1.12	4.19
2048	0.043	0.036	1.56	1.86
3500	0.110	0.123	1.78	1.59

2. Размер блока, один поток, N = 3500

b	Время, с	BW, ГБ/с
4	0.036	5.44
8	0.023	8.52
16	0.018	10.89
32	0.020	9.80
64	0.022	8.91
128	0.028	7.00

3. Число потоков, N = 3500, b* = 16

Потоки	rows_omp, с	S rows_omp	blocked_omp, с	S blocked_omp
1	0.092	1.20	0.019	5.79
2	0.055	2.00	0.013	8.46
4	0.046	2.39	0.011	10.00
8	0.027	4.07	0.010	11.00
16	0.027	4.07	0.010	11.00

4. False sharing, N = 3500, 8 потоков, rows_omp

Стратегия	Время, с	BW, ГБ/с
schedule(static)	0.027	7.26
schedule(static,1)	0.040	4.90
schedule(static,8)	0.028	7.00

Вывод

Обход rows читает A последовательно, но пишет B с шагом N, а cols меняет эти роли; различие заметно с N = 1024, но при N = 3500 rows оказался быстрее cols. Лучший блок b* = 16 дал 0.018 с; два блока по 16×16 занимают 4 КиБ и помещаются в L1d, но выбор оптимума зависит также от ассоциативности кеша и шага доступа. Блокирование уменьшает потери кеш-линий и повышает повторное использование данных. На восьми потоках blocked_omp достигла 0.010 с и S = 11.00 относительно rows. Транспонирование ограничивается пропускной способностью памяти и обменом кеш-линиями, тогда как интеграл ЛР2 выполняет больше вычислений на элемент. При 16 потоках блочная версия не стала быстрее: доступно восемь логических процессоров. При static,1 время выросло с 0.027 до 0.040 с: соседние строки A передаются разным потокам, которые записывают соседние элементы строк B в общие кеш-линии (false sharing); static,8 уменьшает число таких границ и дал 0.028 с.