Лабораторная работа №8

Параллельный BFS с MPI + OpenMP

Среда выполнения: Ubuntu в WSL2, Open MPI 5.0.10, GCC 15.2.0. Intel Core i5-1155G7, 4 физических ядра / 8 логических процессоров; все MPI-процессы работают на одном компьютере.

```
mpicc -O2 -Wall -Wextra -fopenmp bfs.c -o bfs
OMP_NUM_THREADS=2 mpiexec --bind-to none -n 2 ./bfs graph.txt 0 directed dynamic 6
```

1. Представление графа и алгоритм

Задан невзвешенный граф G=(V,E) и начальная вершина s. Требуется найти кратчайшие расстояния d(v) от s; для недостижимых вершин d(v)=-1. Поддерживаются ориентированный и неориентированный режимы, выбор s. Входной файл содержит N, M и пары u v с нумерацией вершин от 0. Граф хранится в CSR: offsets[N+1] и edges[M]. В неориентированном режиме каждая входная пара добавляется в обоих направлениях. В отчёте M - число дуг в CSR.

Последовательный BFS использует очередь: вершина получает расстояние при первом обнаружении. В гибридной версии каждый MPI-процесс хранит полную копию CSR и расстояний. Ранг 0 читает граф и рассылает CSR через MPI_Bcast. Ранг r обрабатывает индексы текущего фронта r, r+P, r+2P, ...; OpenMP распределяет эти вершины между потоками через schedule(runtime), размер блока 1.

Каждый поток добавляет найденные вершины в собственный динамический список; dist в параллельном участке только читается. После OpenMP списки объединяются в локальный массив признаков. MPI_Allreduce с MPI_MAX объединяет признаки всех рангов. Затем каждый процесс в одинаковом порядке обновляет dist и строит следующий фронт, добавляя только ещё не посещённые вершины. Так исключаются гонки и повторные добавления. Обход завершается при пустом фронте. MPI_Init_thread запрашивает MPI_THREAD_FUNNELED; MPI вызывается только главным потоком.

2. Проверка корректности

Пройдены 36 проверок полных векторов расстояний с заранее известным ответом: 6 графов, P=1,2,4, обе планировки OpenMP. Проверены одна вершина, отсутствие рёбер, ромб с повторными обнаружениями, петли, повторные рёбра, цикл, цепочка, недостижимые вершины, s≠0 и оба направления. Процессы без назначенных вершин также участвуют в коллективных операциях. Ещё 11 проверок неверных аргументов и файлов завершились с ошибкой без зависаний.

Во всех 25 конфигурациях измерений расстояния гибридного и последовательного BFS сравнены для каждой вершины на каждом MPI-процессе: число несовпадений равно 0. Для графов эксперимента s=0, недостижимых вершин нет. Число уровней включает уровень начальной вершины.

3. Результаты экспериментов и анализ

Для каждой конфигурации взято среднее 5 повторений после 1 прогрева. Генерация, чтение, построение и рассылка CSR, выделение начальных буферов, проверка и вывод исключены. Инициализация расстояний, обработка фронтов, накопление кандидатов и обмены включены. Перед гибридным BFS выполняется MPI_Barrier; каждый процесс измеряет время MPI_Wtime(), итог - максимум через MPI_Reduce с MPI_MAX. Используется --bind-to none.

Для каждого графа последовательная база Tseq измерена отдельно при P=T=1; она одинакова для всех сравниваемых конфигураций этого графа. Ускорение S=Tseq/Tpar, эффективность E=S/(P·T). В разделах 3.1-3.3 используется один граф: N=50000, M=799999, s=0, Tseq=1.822 мс, планировка dynamic. Вершины соединены цепочкой; из каждой добавлено 15 случайных дуг. Генератор random.Random, seed=2026. В основных таблицах время приведено в секундах, как в задании.

3.1. Влияние числа MPI-процессов; T=2

MPI-процессы	Потоков на процесс	Всего потоков	Время, с	Ускорение
1	2	2	0.002935	0.621
2	2	4	0.002465	0.739
4	2	8	0.023029	0.079
8	2	16*	0.305560	0.006

* 16 потоков превышают 8 доступных логических процессоров. Даже при 8 потоках используется SMT. Дополнительные ранги увеличивают число копий данных и накладные расходы коллективных операций.

3.2. Влияние числа OpenMP-потоков; P=2

MPI-процессы	Потоков на процесс	Всего потоков	Время, с	Ускорение
2	1	2	0.003242	0.562
2	2	4	0.002465	0.739
2	4	8	0.021674	0.084
2	8	16*	0.219561	0.008

В этой серии T=2 быстрее T=1; при T=4 и T=8 время растёт. Размер фронта на первых уровнях мал, а запуск и ожидание потоков, синхронизация и конкуренция за CPU уменьшают пользу параллелизма.

3.3. Одинаковое общее число потоков; P·T=8

MPI-процессы	Потоков на процесс	Всего потоков	Время, с	Ускорение
1	8	8	0.033794	0.054
2	4	8	0.021674	0.084
4	2	8	0.023029	0.079
8	1	8	0.017882	0.102

Одинаковое P·T не означает одинаковое время: меняются количество MPI-обменов, число OpenMP-потоков в процессе, объём дублируемых массивов и характер ожидания. На одном компьютере результат также зависит от планировщика ОС и состояния WSL.

3.4. Размер и структура графа; P=2, T=2

Все графы ориентированные. Случайные графы содержат цепочку и 15 случайных дуг из каждой вершины, разреженный - цепочку и 3 случайные дуги. В графе с хабами к цепочке добавлено 1023 случайные дуги из каждой вершины с номером, кратным 97. Для всех генераторов seed=2026. Цепочка из 1000 вершин содержит только дуги $v \to v+1$. M/N - средняя исходящая степень.

Число вершин |V|	Число рёбер |E|	Средняя степень	Время, с	Ускорение
10000	159999	16.00	0.000412	0.705
50000	799999	16.00	0.002465	0.739
100000	1599999	16.00	0.007713	0.821
50000	199999	4.00	0.002665	0.296
50000	577867	11.56	0.002119	0.416
1000	999	1.00	0.003240	0.001

Строки таблицы: случайные графы на 10000, 50000 и 100000 вершин, разреженный граф, граф с хабами, цепочка. Последовательные времена для них соответственно: 0.000290, 0.001822, 0.006328, 0.000790, 0.000881 и 0.000004310 с.

В таблице приведена планировка dynamic. При росте случайного графа с 10000 до 100000 вершин увеличивается время обхода, а отношение Tseq/Tpar улучшается с 0.705 до 0.821: полезной работы становится больше. Разреженный граф содержит меньше дуг, но больше уровней и обменов, поэтому меньшее M само по себе не гарантирует меньшее время гибридного BFS.

3.5. Размеры фронтов и балансировка нагрузки

Граф	Уровней	max F	Недостижимых	Вершин на рангах P=2
Случ. 10k	6	6496	0	5001 / 4999
Случ. 50k	6	32824	0	25001 / 24999
Случ. 100k	7	50257	0	50002 / 49998
Разреженный	13	21023	0	25002 / 24998
С хабами	5	34838	0	25001 / 24999
Цепочка	1000	1	0	1000 / 0

```
Фронты случайного графа N=50000: 1, 16, 256, 3927, 32824, 12976
Фронты графа с хабами:            1, 1018, 10595, 34838, 3548
Фронты цепочки:                  1000 уровней по 1 вершине
```

У основного случайного графа ранги обработали 400016 и 399983 дуги; у графа с хабами - 273590 и 304277. Хотя число вершин распределено почти поровну, степени вершин создают различие в объёме работы. У цепочки фронт всегда содержит одну вершину, поэтому все 1000 вершин обрабатывает ранг 0, а второй процесс участвует только в обменах. Широкие фронты дают больше независимых задач; узкие ограничивают использование процессов и потоков.

Планировки OpenMP static и dynamic; P=2, T=2

Граф	static, мс	dynamic, мс
Случ. 10k	0.386	0.412
Случ. 50k	2.166	2.465
Случ. 100k	7.240	7.713
Разреженный	2.504	2.665
С хабами	1.814	2.119

В обеих планировках размер блока равен 1. Static заранее распределяет вершины, dynamic выдаёт следующую задачу освободившемуся потоку. Dynamic может помочь при различной степени вершин, но требует дополнительных операций планирования и не делит список соседей одной вершины между потоками. В этой серии static быстрее на всех пяти сравнённых графах, включая граф с хабами; ожидаемая польза балансировки не превысила накладных расходов.

3.6. Стоимость коммуникаций и ограничения памяти

Максимум суммы времён MPI_Allreduce по рангам для основного графа: 0.454 мс, или 18.4% от Tpar. Для цепочки: 2.063 мс, или 63.7%. Эти времена включают ожидание других рангов; максимум времени обменов и максимум времени всего BFS могут относиться к разным процессам. Это не измерение чистой скорости передачи.

На каждом из L уровней объединяется массив N целых чисел. При sizeof(int)=4 логический размер массива равен 4N байт, за обход - 4NL: 1.2 МБ у основного графа и 4 МБ у цепочки. Фактический сетевой трафик зависит от числа рангов и реализации Allreduce. Плотный массив избыточен при малом числе кандидатов; дополнительно каждый ранг сканирует N признаков на уровне. Можно локально удалять повторы и обмениваться только списками кандидатов через MPI_Allgatherv.

Одна копия CSR занимает около 4(N+1+M) байт, без учёта расстояний, фронтов, массивов признаков и списков кандидатов. Суммарная память CSR растёт как O(P(N+M)); списки кандидатов могут содержать повторы. Хранение полного графа на каждом ранге ограничивает масштабирование: добавление процессов не увеличивает допустимый размер графа для одного процесса.

3.7. Ускорение и эффективность

Ускорение S=Tseq/Tpar приведено в основных таблицах. Эффективность E=S/(P·T) учитывает общее число потоков. Например, при P=2 и T=2 для основного графа: S=0.001821833/0.002464549=0.739215, E=0.739215/4=0.184804. Эффективности для строк трёх таблиц в порядке их следования:

```
Число MPI-процессов:        0.3103, 0.1848, 0.0099, 0.0004
Число OpenMP-потоков:       0.2809, 0.1848, 0.0105, 0.0005
Одинаковое число потоков:   0.0067, 0.0105, 0.0099, 0.0127
```

Для таблицы размера и структуры графа при P=T=2 эффективность равна S/4: 0.1761, 0.1848, 0.2051, 0.0741, 0.1039 и 0.0003 соответственно.

4. Вывод

Выполнены все проверки расстояний, собраны фронты, нагрузка по рангам и времена обхода с коммуникациями. В исследованных конфигурациях ускорение относительно последовательной базы не получено: S<1. Заметны расходы на формирование фронтов, сканирование плотных массивов и ожидание MPI/OpenMP; при превышении числа доступных CPU время резко растёт. Результаты описывают локальные запуски в WSL и не характеризуют производительность кластера. Полные значения измерений и статистика фронтов сохранены в measurements.csv.